Documento de análisis del dataset

Tarea 3 – IIC3103

Nombre: Gaspar Magna Rodríguez

Pontificia Universidad Católica de Chile

Índice

1. Descripción del dataset **2**

2. Exploración del mapa **2**
2.1. ¿Qué temas aparecen? 2
2.2. ¿Qué destinos aparecen? 2
2.3. ¿Hay clusters? 2
2.4. ¿Hay chunks duplicados? 2
2.5. ¿Hay chunks irrelevantes? 2

3. Resultados de búsqueda **3**
3.1. ¿Qué pasa al buscar “playas”? 3
3.2. ¿Qué pasa al buscar “castillos”? 3
3.3. ¿Qué pasa al buscar “comidas romántica”? 3

4. Conclusión **3**

1. Descripción del dataset

- URL: https://atlas.nomic.ai/data/gasparmagnar/integratrip-magazines/map
- Identificador: gasparmagnar/integratrip-magazines
- Revistas utilizadas: 10
- Cantidad de chunks: 2013
- Revistas con su cantidad de chunks:

Revista	**Cantidad de chunks**
Traveling 69	213
Traveling 70	217
Traveling 71	225
Traveling 72	232
Traveling 73	194
Traveling 74	203
Traveling 75	192
Traveling 76	197
Traveling 77	171
Traveling 78	169
Total	**2.013**

Cuadro 1: Cantidad de chunks por revista del dataset.

2. Exploración del mapa

2.1. ¿Qué temas aparecen?

Los temas que predominan son los destinos turísticos, gastronomía, vinos, arquitectura, cultura y naturaleza. Esto se puede evidenciar con las etiquetas y encabezados de los grupos que aparecen en el mapa.

2.2. ¿Qué destinos aparecen?

En cuanto a los destinos, aparecen lugares como Algarve, Huelva, Lipari, Costa Rica, Asturias, Burgos, La Rioja, Castellón, entre otros. En el campo headings de los chunks se pueden ver muchos de estos destinos.

2.3. ¿Hay clusters?

Sí. Se observan algunas agrupaciones relacionadas con destinos, gastronomía, arquitectura y contenido editorial.

2.4. ¿Hay chunks duplicados?

Sí. Existen correos y créditos que se repiten en distintas ediciones.

2.5. ¿Hay chunks irrelevantes?

Sí, ya que existen chunks compuestos solo por créditos, correos, datos, publicidad, que aportan poco a las consultas turísticas.

3. Resultados de búsqueda

3.1. ¿Qué pasa al buscar "playas"?

Se obtienen resultados relacionados con el Algarve, Playa de los Catedrales, Playa Naranjo, Canneto y Huelva. Los resultados son pertinentes y provenientes de distintos destinos costeros.

3.2. ¿Qué pasa al buscar "castillos"?

Aparecen resultados sobre el Fuerte de San Felipe, Santa Gadea del Cid y el Castillo de los Velasco. Los resultados incluyen lugares de patrimonio histórico relacionados semánticamente con la búsqueda.

3.3. ¿Qué pasa al buscar "comidas romántica"?

El resultado principal es el restaurante VelascoAbellà, descrito como un lugar adecuado para una cena romántica. Esto muestra que la búsqueda reconoce el significado de la consulta aunque no dependa solamente de palabras exactas.

4. Conclusión

El dataset contiene diversa información sobre destinos, gastronomía, cultura, arquitectura y naturaleza. Las búsquedas entregaron resultados pertinentes, incluso para consultas semánticas, como lo puede ser "comidas románticas", por lo que el dataset resulta adecuado para el sistema RAG. Como punto negativo, se detectaron chunks duplicados e irrelevantes, principalmente créditos, contactos y publicidad, cuya eliminación podría mejorar la calidad de las búsquedas.